

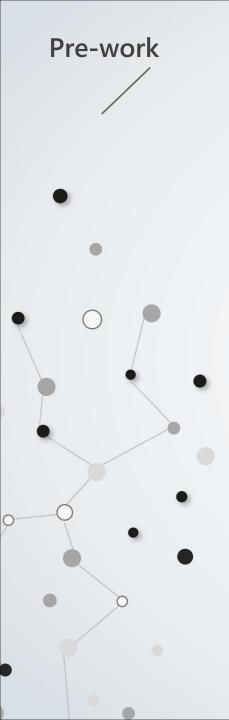
Catalog

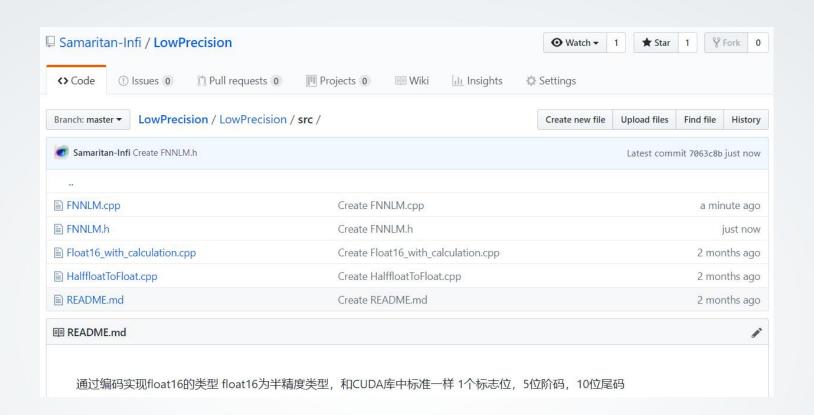
低精度相关工作

CPU环境下编写Float16

相关文献阅读

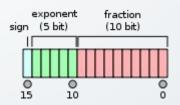
三 分类器替换理论部分





- CPU: Float16
- 与Float32的转换 & 计算

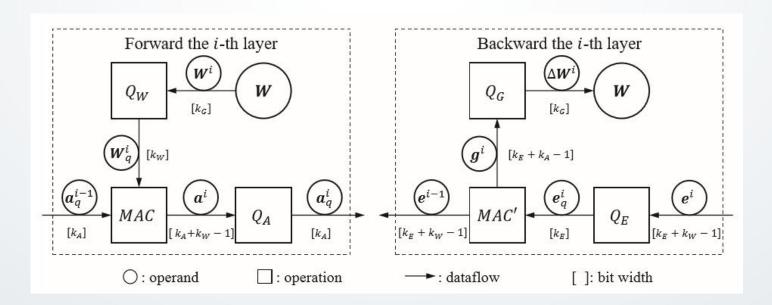
半精度类型,参照CUDA库中定义标准 1个标志位,5位阶码,10位尾码



Introduction

- 精度降低至float16 / int8
- 二值网络
- 参数修剪

WAGE





Related Work

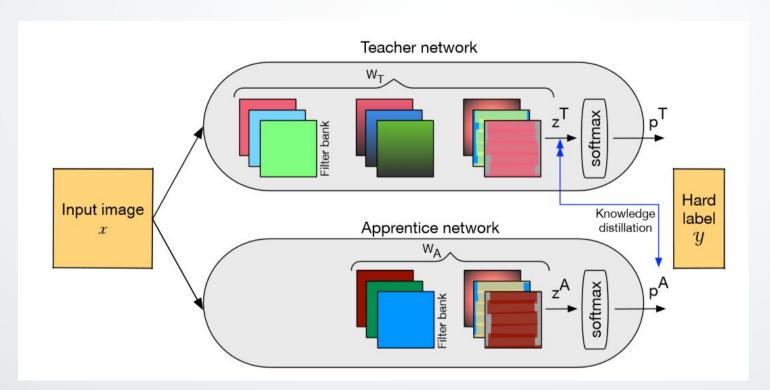
知识蒸馏(knowledge distillation)

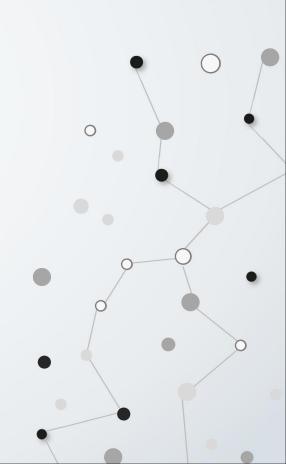
将知识从一个复杂的网络转移到一个更小的网络中。

low-precision

$$\mathcal{L}(x; W_T, W_A) = \alpha \mathcal{H}(y, p^T) + \beta \mathcal{H}(y, p^A) + \gamma \mathcal{H}(z^T, p^A)$$

H(·) 表示损失函数





Related Work

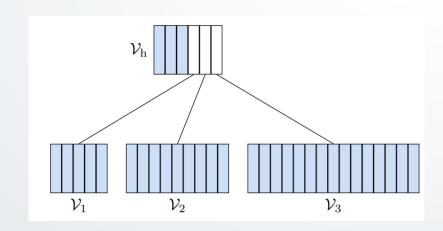
层次 softmax (hierarchical softmax)

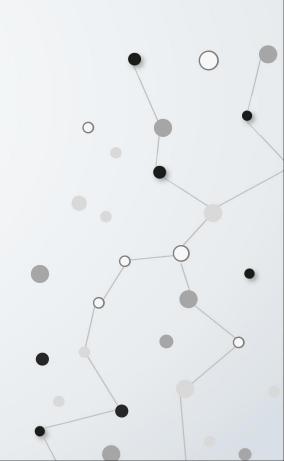
$$p(w | h) = p_1(C(w) | h) \times p_2(w | C(w), h)$$

复杂度 O(dk) 降低至 $O(d\sqrt{k})$

适应性 softmax (adaptive softmax)

通常情况下, 20% 的词表可以覆盖 87% 的文档内容





Theory

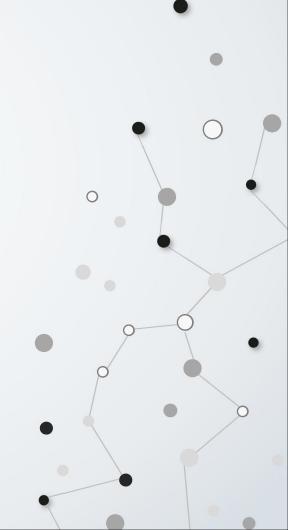
目标: 使整形的精度能够通过分类器, 以提高速度

$$\log_{\text{softmax}}(z_w) = \log(\frac{\exp(z_w)}{\sum_{w' \in v} \exp(z_{w'})})$$

初始,尝试直接通过线性函数直接去拟合分类公式包括泰勒展开, k^x

$$e^x = \sum_{n=1}^{\infty} \frac{x^n}{n!}$$
 $\ln(1+x) = \sum_{n=1}^{\infty} \frac{(-1)^{n+1}}{n} x^n$

由于泰勒拟合的函数只在一定定义域内保持性质,超出之后会发生突变,在语言模型中测试时无法收敛。



Theory

$$\begin{split} \log_{-} & \operatorname{softmax}(z_{w}) = \log(\frac{\exp(z_{w})}{\sum_{w' \in \mathcal{V}} \exp(z_{w'})}) \\ & Float_{w} \xrightarrow{-scale(x)} Int_{w} \\ & Log_{-} softMax(z_{w}) = \log(\exp(z_{w})) - \log(\sum_{w' \in \mathcal{V}} \exp(z_{w'})) \\ & Log_{-} softMax(z_{w}) \approx z_{w} - \log(\sum_{w' \in \mathcal{V}} \exp(z_{w'})) \\ & \sum_{w' \in \mathcal{V}} 2^{z_{w'}} = a_{0} 2^{0} + a_{1} 2^{1} + \dots + a_{n} 2^{n} (a_{i} \in \{0,1\}, a_{n} = 1) \\ & \sum_{w' \in \mathcal{V}} \exp(z_{w'}) \approx a_{0} \exp(0) + a_{1} \exp(1) + \dots + a_{n} \exp(n) (a_{i} \in \{0,1\}, a_{n} = 1) \\ & \exp(n) \leq \sum_{w' \in \mathcal{V}} \exp(z_{w'}) \leq \exp(n+1) \\ & n \leq \log(\sum_{w' \in \mathcal{V}} \exp(z_{w'})) \leq n+1 \\ & n = \max(z_{w'}) + b, b \geq 0 \\ & Log_{-} softMax(z_{w}) \approx z_{w} - \max(z_{w'}) - b, b \geq 0 \end{split}$$

在Neu.Trans中FNNLM的语言模型上尝试修改

修改了前向过程最后输出的分类器

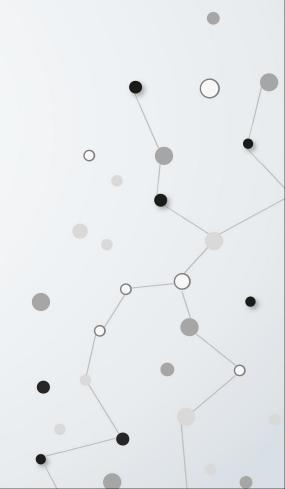
收敛时间较基线明显缩短

统计计算时间

在一个epoch内:

基线计算softmax的时间为 1.723192 秒

尝试修改后的计算时间为 0.956978 秒

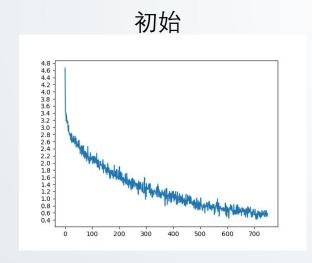


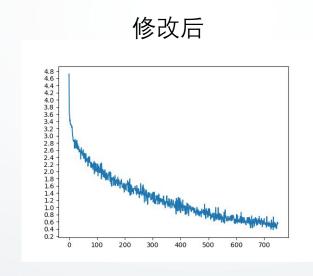
在一个基于RNN和Attention机制 Sequence to Sequence 的翻译模型上修改

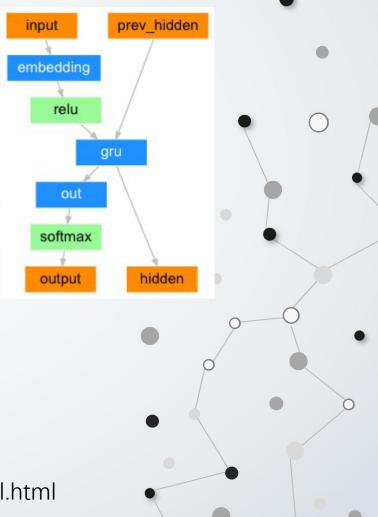
修改了decoder中输出的分类器

decoder的输出会影响到训练的反向过程

loss图像如下, 前后收敛过程相近







https://pytorch.org/tutorials/intermediate/seq2seq_translation_tutorial.html

在一个基于RNN和Attention机制 Sequence to Sequence 的翻译模型上修改

训练数据量 10599

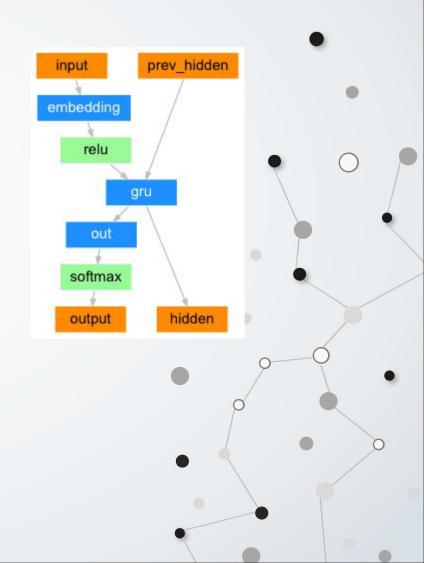
测试数据 1000

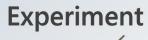
(数据均为简单句子)

测试BLUE值结果:

初始: 72.83

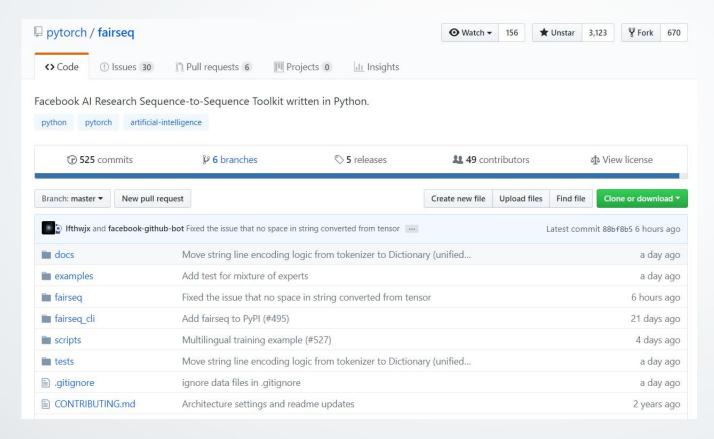
修改后: 73.04

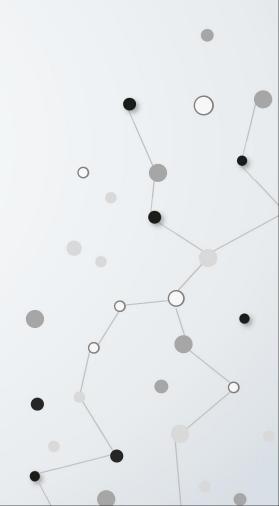




在FaceBook的fairseq翻译模型上尝试修改

这里直接采用它提供的预先训练的模型进行测试,直接修改其最后的decoder输出部分的分类器



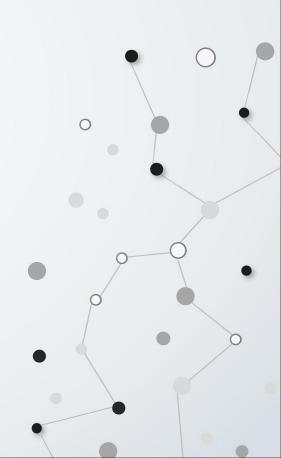


在FaceBook的fairseq翻译模型上尝试修改

这里直接采用它提供的预先训练的模型进行测试,直接修改其最后的decoder输出部分的分类器

Pre-trained models 测试模型

Description	Dataset	Model	Test set(s) newstest2014: download (.tar.bz2) newstest2012/2013: download (.tar.bz2)	
Convolutional (Gehring et al., 2017)	WMT14 English-French	download (.tar.bz2)		
Convolutional (Gehring et al., 2017)	WMT14 English-German	download (.tar.bz2)	newstest2014: download (.tar.bz2)	
Transformer (Ott et al., 2018)	WMT14 English-French	download (.tar.bz2)	newstest2014 (shared vocab): download (.tar.bz2)	
Transformer (Ott et al., 2018)	WMT16 English-German	download (.tar.bz2)	newstest2014 (shared vocab): download (.tar.bz2)	

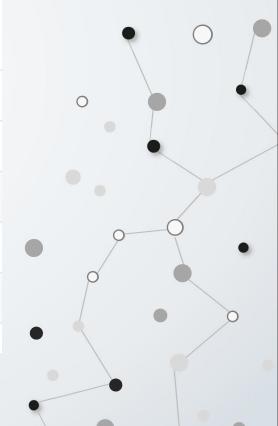


在FaceBook的fairseq翻译模型上尝试修改

这里直接采用它提供的预先训练的模型进行测试,直接修改其最后的decoder输出部分的分类器

测试结果

Model	Origin BLUES	Now BLUES	Percent
CNN - WMT14 English-French	40.83	40.08	98.163%
CNN - WMT14 English-German	25.70	24.80	96.498%
Transformer - WMT14 English-French	43.00	42.26	98.279%
Transformer - WMT16 English-German	29.23	28.68	98.118%

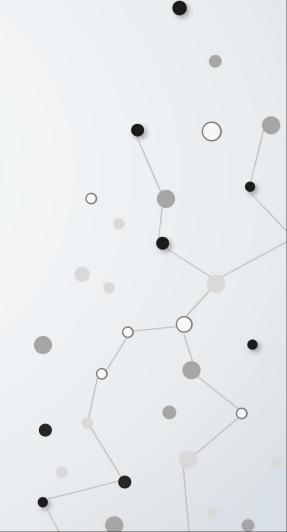


Conclusion

为了能够支持整形精度的解码,采用了线性方式的分类器来替代原先的 softmax。

替换后,支持整数精度,时间上也有所下降,但是准确性目前效果并不理想,后续应有更多的学习,尝试与完善。

当指数分类器能够被较为理想的替换后,可以尝试将整个decoder替换为整形精度,测试其速度与准确率。



感谢聆听



AIM AT